PROYECTO #1

Exploratory Data Analysis (EDA)

Dataset: Predict Future Sales (Kaggle)

Para completar el EDA el grupo deberá desarrollar los siguientes pasos, trabajando sobre el dataset **Predict Future Sales** de Kaggle. El dataset contiene las ventas diarias de una cadena de tiendas rusas (1C Company) y el objetivo final de la competencia es predecir las ventas **mensuales** de cada par tienda-producto para noviembre de 2015. Este EDA prepara el terreno para esa etapa de *forecasting*.

> **Uso de IA:** se permite utilizar herramientas de inteligencia artificial para desarrollar este proyecto, específicamente **Claude Code dentro de VSCode**.

> **Descarga del dataset:** kaggle.com/competitions/competitive-data-science-predict-future-sales/data (requiere cuenta gratuita de Kaggle). Los archivos se colocan en `data/raw/` y **no se suben al repositorio**.

Archivos del dataset

Archivo	Contenido	Columnas
`sales_train.csv`	Ventas diarias históricas (train): una fila por producto vendido en una tienda un día	date, date_block_num, shop_id, item_id, item_price, item_cnt_day
`items.csv`	Catálogo de productos	item_name, item_id, item_category_id
`item_categories.csv`	Catálogo de categorías	item_category_name, item_category_id
`shops.csv`	Catálogo de tiendas (sucursales)	shop_name, shop_id
`test.csv`	Pares tienda-producto a predecir (nov 2015)	ID, shop_id, item_id

Nota: `date_block_num` es el número de mes consecutivo (0 = enero 2013, 33 = octubre 2015) e `item_cnt_day` es la cantidad vendida en el día (los valores negativos representan devoluciones). El dataset no trae una columna de ventas en dinero: el grupo deberá construirla como `item_price x item_cnt_day`.

1. Estructura del proyecto y repositorio

a. Descargar la plantilla de **cookiecutter** (Data Science) para definir la estructura del proyecto.

b. Crear el notebook `01_exploratory_data_analysis.ipynb`.

c. Crear un repositorio local con **git**.

d. Agregar la configuración necesaria en el archivo `.gitignore` (los datos de Kaggle pesan ~100 MB y no deben versionarse).

e. Publicar el repositorio en **GitHub**.

f. Cada miembro del equipo deberá mostrar un *screenshot* donde hace un *pull* del repositorio para trabajar de forma local en su computadora.

2. Comprensión inicial del dataset

a. Cargar los archivos del dataset y visualizar las primeras filas de cada uno.

b. Mostrar el tamaño de cada tabla (número de filas y columnas).

c. Describir brevemente qué representa cada columna (`date`, `date_block_num`, `shop_id`, `item_id`, `item_price`, `item_cnt_day`, `item_name`, `item_category_id`, `item_category_name`, `shop_name`) y cuál es la variable objetivo.

d. Identificar el rango temporal de los datos (fecha mínima y máxima) y el número de meses cubiertos.

3. Validación de la estructura de los datos

a. Verificar los tipos de datos de cada variable (fecha, numérica, categórica).

b. Confirmar que la columna `date` esté correctamente formateada como tipo *datetime* (en el archivo original viene como texto con formato `dd.mm.aaaa`).

c. Validar la frecuencia temporal: los datos son transacciones diarias, por lo que se debe revisar si existen días sin ventas y si `date_block_num` es consistente con la fecha. Concluir a qué frecuencia conviene agregar (diaria, semanal o mensual).

4. Análisis de valores faltantes y duplicados

a. Identificar columnas con valores nulos y el porcentaje de datos faltantes.

b. Definir la estrategia para tratarlos (eliminación, imputación, etc.). Revisar además valores inválidos que no son nulos, como **precios menores o iguales a cero** y **cantidades negativas** (devoluciones).

c. Verificar y justificar cómo se manejarán los registros duplicados. Revisar también si existen **tiendas repetidas** en `shops.csv` (mismo nombre con distinto ID).

5. Análisis descriptivo general

a. Calcular métricas estadísticas básicas: media, mediana, mínimo, máximo y desviación estándar de `item_price`, `item_cnt_day` y de los ingresos.

b. Analizar la distribución de ventas por:

- **i.** Producto (y categoría de producto)
- **ii.** Sucursal (tienda)
- **iii.** Periodo de tiempo (día, semana, mes, año)

6. Exploración temporal

a. Graficar la evolución de las ventas a lo largo del tiempo.

b. Identificar patrones de:

- **i.** Tendencia
- **ii.** Estacionalidad
- **iii.** Picos o caídas abruptas
- **iv.** Analizar si hay ciclos por días de la semana o meses del año.

7. Análisis comparativo entre sucursales y productos

a. Identificar los productos (y categorías) más vendidos y menos vendidos.

b. Comparar el desempeño entre sucursales.

c. Detectar *outliers* o comportamientos anómalos por sucursal o producto (por ejemplo, transacciones con cantidades o precios extremadamente altos).

8. Visualizaciones clave (obligatorias)

a. Serie de tiempo de ventas totales.

b. Gráfico de barras comparando ventas por sucursal.

c. Gráfico de barras comparando ventas por producto (top N) y por categoría.

d. *Heatmap* o matriz para visualizar el comportamiento de las ventas en el tiempo y por sucursal/categoría.

9. Autocorrelación (ACF) y autocorrelación parcial (PACF)

Para cada serie temporal específica: **ventas totales**, **ventas por sucursal**, **ventas por producto** y **ventas por sucursal-producto**. Dado que el dataset tiene 60 tiendas y más de 21,000 productos, se trabajará con una selección representativa (por ejemplo, las series con más ventas). Se recomienda agregar a nivel mensual (34 observaciones) y, para la serie total, también a nivel diario.

a. Aplicar:

- **i.** Gráfico de Autocorrelación (ACF): muestra la dependencia entre la serie y sus rezagos.
- **ii.** Gráfico de Autocorrelación Parcial (PACF): ayuda a identificar la cantidad de términos AR (autorregresivos) que deben incluirse.

b. Interpretar:

- **i.** ¿Existen correlaciones significativas a diferentes rezagos?
- **ii.** ¿Se observa estacionalidad reflejada en patrones repetitivos?

10. Insights y conclusiones del EDA

a. Identificar variables que afectan directamente las ventas.

b. Detectar patrones útiles para el modelo de *forecasting* (incluyendo qué porcentaje de los pares tienda-producto de `test.csv` tiene historial en el train).

c. Concluir sobre la calidad y preparación del dataset para las etapas siguientes del proyecto.

Entregables

> 1) Enlace al repositorio de GitHub con la estructura de cookiecutter.
> 2) Notebook `01_exploratory_data_analysis.ipynb` ejecutado, con gráficas e interpretaciones escritas.
> 3) Screenshots del *pull* de cada integrante del equipo.